

RELATÓRIO TÉCNICO

Predição de Diabetes com Análise Exploratória, Teorema de Bayes e Classificação

Disciplina: Estatística e Probabilidade

Dataset: Diabetes Prediction Dataset - Kaggle

Link do dataset: <https://www.kaggle.com/datasets/iammustafatz/diabetes-prediction-dataset>

Integrantes: Felipe Alho, Pedro Sales, Josiel Costa

Repositório GitHub: inserir o link do repositório

1. Descrição do dataset

O projeto utilizou o Diabetes Prediction Dataset, disponibilizado na plataforma Kaggle. O conjunto original possui 100.000 registros e 9 atributos relacionados a características demográficas, condições clínicas e exames laboratoriais. A variável alvo da análise é diabetes, codificada como 0 para não diabético e 1 para diabético.

Item	Descrição
Origem	Kaggle - Diabetes Prediction Dataset
Domínio	Saúde / predição de diabetes
Registros originais	100.000
Atributos originais	9
Registros após tratamento	94.032
Variável alvo	diabetes

As variáveis utilizadas foram: gender, age, hypertension, heart_disease, smoking_history, bmi, HbA1c_level, blood_glucose_level e diabetes. Após a limpeza, também foram criadas as variáveis derivadas faixa_etaria, faixa_bmi e glicose_alta.

2. Justificativa da escolha

O dataset foi escolhido porque permite trabalhar com variáveis qualitativas e quantitativas, e exige tratamento prévio dos dados e possui uma variável categórica clara para classificação. Além disso, o tema apresenta aplicação prática, pois a predição de diabetes pode ser estudada com base em fatores como idade, IMC, glicemia, HbA1c, hipertensão, doença cardíaca e histórico de tabagismo.

A base também é adequada para o objetivo da disciplina, pois permite desenvolver análise exploratória, cálculo de probabilidades com o Teorema de Bayes, aplicação de algoritmos de classificação e apresentação dos resultados em dashboard interativo.

3. Tratamento e limpeza dos dados

A limpeza foi realizada antes da análise exploratória e da modelagem, buscando reduzir inconsistências e tornar os dados mais adequados para interpretação estatística.

Tratamento	Justificativa técnica	Impacto esperado
Remoção de duplicatas	Foram identificados 3.854 registros duplicados no dataset original.	Evita repetição artificial de observações e reduz viés nas frequências e nos modelos.
Remoção da categoria Other em gender	Após retirar duplicatas, havia 18 registros nessa categoria, representando proporção muito pequena.	Reduz ruído em uma categoria com baixa representatividade.
Tratamento de smoking_history	As categorias foram agrupadas: ever foi incorporada a current; not current foi incorporada a former; No Info foi tratada como desconhecido.	Simplifica categorias próximas e melhora a leitura dos gráficos e modelos.
Remoção de idades menores que 2 anos	Foram removidos 2.096 registros com idade menor que 2 anos.	Evita distorção causada por perfis infantis muito distantes do foco principal da base.
Tratamento de outliers em BMI	Foram detectados valores extremos de IMC pelo método IQR. Foi aplicada winsorização nos percentis 1% e 99%.	Reduz influência de valores extremos sem eliminar grande volume de registros.
Engenharia de atributos	Foram criadas faixa_etaria, faixa_bmi e glicose_alta.	Facilita análise por grupos e permite aplicação didática do Teorema de Bayes.

Após os tratamentos, a base final utilizada no dashboard e nos modelos ficou com 94.032 registros.

4. Análise exploratória dos dados

A análise exploratória indicou desbalanceamento da variável alvo: 85.550 registros foram classificados como não diabéticos e 8.482 como diabéticos. Assim, a prevalência de diabetes na base tratada foi de aproximadamente 9,02%.

Indicador	Resultado
Total de registros tratados	94.032
Não diabéticos	85.550 (90,98%)
Diabéticos	8.482 (9,02%)
Idade média / mediana	42,70 anos / 44 anos
IMC médio / mediano	27,48 / 27,32
Glicose média / mediana	138,34 mg/dL / 140 mg/dL

4.1 Principais insights

- A taxa de diabetes aumentou conforme a idade: foi menor que 1% em menores de 18 anos e chegou a 20,82% em pessoas acima de 60 anos.
- O IMC mostrou relação importante com o diabetes: pessoas com obesidade mórbida apresentaram taxa de 25,87%, enquanto indivíduos com IMC normal apresentaram 3,97%.
- A presença de hipertensão esteve associada a maior proporção de diabetes: 27,96% entre hipertensos contra 7,39% entre não hipertensos.
- A doença cardíaca também apresentou relação relevante: 32,30% entre indivíduos com doença cardíaca contra 8,01% entre os demais.
- Na árvore de decisão, HbA1c_level e blood_glucose_level foram as variáveis mais importantes para a classificação, indicando forte peso dos marcadores laboratoriais.

Grupo	Taxa de diabetes
< 18 anos	0,59%
18-30 anos	1,43%
31-45 anos	4,70%
46-60 anos	11,79%
> 60 anos	20,82%
IMC normal	3,97%
Obesidade mórbida	25,87%
Com hipertensão	27,96%
Com doença cardíaca	32,30%

5. Análise probabilística pelo Teorema de Bayes

Para a aplicação do Teorema de Bayes, a variável alvo foi diabetes e a evidência utilizada foi glicose_alta, definida como 1 quando blood_glucose_level foi maior ou igual a 126 mg/dL e 0 quando foi menor que 126 mg/dL.

A fórmula utilizada foi: $P(C|X) = [P(X|C) \times P(C)] / P(X)$, em que C representa a classe diabético e X representa a evidência glicose alta.

Probabilidade	Valor
P(diabético)	0,0902 (9,02%)
P(glicose alta)	0,7195 (71,95%)
P(glicose alta diabético)	1,0000 (100,00%)
P(glicose alta não diabético)	0,6917 (69,17%)
P(diabético glicose alta)	0,1254 (12,54%)
P(diabético glicose normal)	0,0000 (0,00%)

A interpretação do resultado mostra que, antes de observar a glicose, a probabilidade de diabetes na base era de 9,02%. Ao observar glicose alta, essa probabilidade aumentou para 12,54%. No conjunto tratado, todos os

registros diabéticos apresentaram glicose classificada como alta pelo limiar adotado, por isso a probabilidade de diabetes dado glicose normal foi igual a 0%.

Essa abordagem é útil para demonstrar como uma evidência observada atualiza a probabilidade inicial de uma classe. Entretanto, por usar apenas uma evidência, ela é mais simples que os modelos multivariados de classificação.

6. Algoritmos de classificação

Foram implementados dois algoritmos de classificação: Árvore de Decisão e K-Nearest Neighbors (KNN). A base foi dividida em treino e teste na proporção 80/20, com estratificação da variável alvo para preservar o desbalanceamento entre as classes.

As variáveis explicativas usadas nos modelos foram: age, bmi, HbA1c_level, blood_glucose_level, gender, smoking_history, hypertension e heart_disease. As variáveis categóricas foram codificadas com LabelEncoder. No KNN, também foi aplicada padronização com StandardScaler, pois esse algoritmo é sensível à escala das variáveis.

Modelo	Acurácia	Precisão	Recall	F1-score
Árvore de Decisão	0,9707	1,0000	0,6751	0,8061
KNN	0,9605	0,9360	0,6032	0,7336

Modelo	Matriz de confusão
Árvore de Decisão	[[17111, 0], [551, 1145]]
KNN	[[17041, 70], [673, 1023]]

A Árvore de Decisão apresentou melhor desempenho geral, com maior acurácia e F1-score. O modelo teve precisão de 100% para a classe diabético, ou seja, entre os casos que classificou como diabéticos, não houve falso positivo no conjunto de teste. Porém, o recall foi de 67,51%, indicando que parte dos diabéticos reais ainda não foi identificada pelo modelo.

O KNN também apresentou bom desempenho, mas com recall menor para a classe diabético. Isso indica maior dificuldade para detectar todos os casos positivos, especialmente por causa do desbalanceamento da base.

7. Dashboard interativo

O dashboard foi desenvolvido em Streamlit e organizado em três abas principais: Análise dos Dados, Teorema de Bayes e Classificação. A primeira aba apresenta filtros e gráficos da análise exploratória; a segunda mostra o cálculo bayesiano com limiar ajustável de glicose; e a terceira compara os algoritmos e permite classificar um novo paciente a partir de dados informados pelo usuário.

As visualizações foram construídas para facilitar a interpretação dos padrões encontrados, especialmente a relação entre diabetes, idade, IMC, comorbidades e marcadores laboratoriais.

8. Conclusões

O projeto demonstrou que a ocorrência de diabetes no dataset está associada principalmente a marcadores laboratoriais, como HbA1c e glicose sanguínea, além de fatores clínicos e demográficos como idade, IMC, hipertensão e doença cardíaca.

A aplicação do Teorema de Bayes permitiu compreender como uma evidência isolada, glicose alta, altera a probabilidade de diabetes. Já os algoritmos de classificação permitiram considerar várias variáveis ao mesmo tempo, com melhor capacidade preditiva. Entre os modelos testados, a Árvore de Decisão apresentou o melhor desempenho geral.

Como limitação, destaca-se o desbalanceamento da variável alvo, já que a classe diabético representa apenas cerca de 9% da base. Em trabalhos futuros, poderiam ser testadas técnicas de balanceamento, validação cruzada e outros modelos, como Random Forest ou Regressão Logística.

9. Referência do dataset

Kaggle. Diabetes Prediction Dataset. Disponível em:

<https://www.kaggle.com/datasets/iammustafatz/diabetes-prediction-dataset>

10. Observação sobre uso de IA generativa

Este relatório técnico pode ser acompanhado de uma declaração separada de uso de IA generativa, conforme solicitado na proposta da disciplina. Sugere-se declarar o uso da IA como apoio para organização textual do relatório, revisão da escrita e explicação dos conceitos, sem substituir a execução, interpretação e defesa do projeto pela equipe.